

Curso: Análisis de Datos

Práctico 1

Obtención, Exploración y Pretratamiento de Datos

Dataset: Garments Worker Productivity (Tema_11.csv)

Entrega: Marzo 2026

Integrantes: Azael Pignanessi | Facundo Sansalone

Objetivos

El presente práctico tiene como objetivo explorar, comprender y preprocesar el dataset del proyecto final — registros diarios de productividad de trabajadores en una fábrica textil de Bangladesh — de forma que quede en condiciones adecuadas para su uso en etapas posteriores del proyecto.

En particular, se busca:

- Conocer en profundidad las variables del dataset y su naturaleza.
- Detectar problemas de calidad de datos: valores faltantes, duplicados e inconsistencias.
- Tomar decisiones fundamentadas sobre cómo tratar cada problema encontrado.
- Normalizar las variables numéricas continuas e investigar las ventajas de esta práctica.
- Comparar los hallazgos del análisis manual con los del informe de Data Profiling.

Alcance

El análisis cubre el dataset completo `Tema_11.csv` (1 207 registros, 15 variables). El trabajo incluye el análisis exploratorio con estadísticas y gráficos, la limpieza y corrección de los datos, y la normalización de variables continuas. No se desarrollan modelos predictivos en este práctico; eso corresponde a etapas posteriores del proyecto final.

1. Descripción de las Variables

El dataset registra la actividad diaria de equipos de trabajo en una fábrica de prendas de vestir. Cada fila representa un equipo en un día específico. La variable objetivo es `actual_productivity`: la productividad real alcanzada por el equipo (escala 0–1).

#	Variable	Tipo	Descripción
---	----------	------	-------------

1	date	Fecha	Fecha del registro (MM/DD/AAAA).
2	quarter	Categorica	Cuarto del mes (Quarter1–Quarter4/5).
3	department	Categorica	Departamento: <i>sewing</i> (costura) o <i>finishing</i> (acabado).
4	day	Categorica	Día de la semana.
5	team	Numérica	Identificador numérico del equipo.
6	no_of_workers	Numérica	Cantidad de trabajadores en el equipo.
7	no_of_style_change	Numérica	Cantidad de cambios de estilo de producto realizados.
8	targeted_productivity	Numérica	Meta de productividad asignada por la gerencia (0–1).
9	smv	Numérica	Standard Minute Value: tiempo estándar asignado a la tarea (minutos).
10	wip	Numérica	Work In Progress: unidades en proceso sin terminar.
11	over_time	Numérica	Tiempo extra del equipo ese día (en minutos).
12	incentive	Numérica	Incentivo económico otorgado al equipo (en BDT).
13	idle_time	Numérica	Tiempo de interrupción de la producción (minutos).
14	idle_men	Numérica	Trabajadores inactivos durante la interrupción.
15	actual_productivity	Numérica	Variable objetivo. Productividad real alcanzada (0–1).

2. Análisis Exploratorio

a. Dimensiones del dataset

1 207 Filas (registros)	15 Columnas (variables)	10 Filas duplicadas	1 380 Celdas faltantes
-----------------------------------	-----------------------------------	-------------------------------	----------------------------------

b. Primeras 5 filas

date	quarter	department	day	team	targ_prod	smv	wip	over_time	incentive
1/1/2015	Quarter1	sweing	Thursday	8.0	0.80	26.16	1108.0	7080.0	98.0
1/1/2015	Quarter1	finishing	Thursday	1.0	0.75	3.94	NaN	960.0	0.0
1/1/2015	Quarter1	sweing	Thursday	11.0	0.80	11.41	968.0	3660.0	50.0
1/1/2015	Quarter1	sweing	Thursday	12.0	0.80	11.41	968.0	3660.0	50.0
1/1/2015	Quarter1	sweing	Thursday	6.0	0.80	25.90	NaN	1920.0	50.0

En rojo: problemas detectados desde la primera inspección (tipo "sweing", espacio en "finishing ", valores NaN).

c. Valores faltantes y duplicados

Se encontraron **10 filas duplicadas** (0.83% del total) y valores faltantes en las 15 columnas. La

columna `wip` concentra la mayor ausencia (44.66%), mientras el resto presenta ~5%, lo que sugiere la existencia de aproximadamente 60 filas completamente vacías.




Figura 1. Porcentaje de valores faltantes por columna. En naranja las columnas con ~5%; en rojo oscuro `wip` con 44.66%.

Variable	Nulos	Porcentaje	Tipo de faltante
wip	539	44.66%	Estructural
date	62	5.14%	MAR
day	61	5.05%	MAR
targeted_productivity	61	5.05%	MAR
idle_time	61	5.05%	MNAR
department	60	4.97%	MAR
quarter	60	4.97%	MAR
no_of_workers	60	4.97%	MAR
no_of_style_change	60	4.97%	MNAR
incentive	60	4.97%	MNAR
idle_men	60	4.97%	MNAR
actual_productivity	60	4.97%	MAR
team	59	4.89%	MAR + inconsistencia
smv	59	4.89%	MAR
over_time	58	4.81%	MAR

d. Causas de los valores faltantes

Faltante Estructural

wip — 539 nulos (44.66%): el departamento *finishing* no registra unidades en proceso por diseño del flujo productivo. Cuando una prenda llega a esa etapa, no hay unidades intermedias que contabilizar. Es un faltante esperado, no un error de datos.

MAR — Missing At Random

Las columnas `date`, `day`, `quarter`, `department`, `team`, `smv`, `targeted_productivity`, `over_time`, `no_of_workers` y `actual_productivity` presentan aproximadamente 60 nulos cada una. La coincidencia en el conteo sugiere unas **60 filas completamente vacías** — registros creados en el sistema pero nunca completados con datos reales.

MNAR — Missing Not At Random

`incentive`, `idle_time`, `idle_men` y `no_of_style_change`: cuando no se otorgó incentivo, no hubo interrupción o no se realizaron cambios de estilo, el campo simplemente no se completa. La ausencia del valor representa el valor 0, no un error.

e. Valores únicos de variables discretas

Variable	Valores únicos	Observación
department	3 (debería ser 2)	"sweing", "finishing", "finishing " — typo y espacio sobrante
quarter	5	Quarter1, Quarter2, Quarter3, Quarter4, Quarter5
day	6	Monday, Tuesday, Wednesday, Thursday, Saturday, Sunday
team	13 (debería ser 12)	Equipos 1–12 + valor inválido "invalid_value"
no_of_style_change	3	0, 1, 2
idle_men	9	0, 1, 2, 3, 4, 5, 7, 15, 45

f. Histogramas de variables discretas y continuas




Figura 2. Distribución de variables discretas. Se observa la predominancia del departamento sewing, mayor actividad en Quarter1 y Quarter4, y alta concentración de valores 0 en cambios de estilo y trabajadores inactivos.




Figura 3. Distribución de variables continuas. Las líneas amarillas indican la mediana de cada variable. Nótese la alta asimetría en incentive, idle_time e idle_men (mayoría en cero), y la presencia de outliers extremos en smv, over_time y actual_productivity.

g. Datos inconsistentes detectados




Figura 4. Boxplots de las tres variables con outliers más extremos. Los puntos por encima del bigote superior son valores atípicos.

#	Variable	Problema	Evidencia
1	<code>department</code>	Typo: "sweing" en lugar de "sewing"	Aparece como 3ª categoría en <code>unique()</code>
2	<code>department</code>	Espacio sobrante: "finishing "	Genera duplicación de categoría
3	<code>team</code>	Valor no numérico: "invalid_value"	dtype object en columna que debería ser int
4	<code>smv</code>	Outlier extremo: 545.6 min (mediana = 15.26 min)	~36× la mediana; imposible para tarea textil
5	<code>over_time</code>	Outlier imposible: 129 600 min = 90 días laborales en un solo día	Físicamente inviable; mediana = 4 080 min
6	<code>actual_productivity</code>	43 valores fuera del rango [0,1]: 11 registros con valor 11.204375 y 32 registros entre (1, 1.2]	La variable es un porcentaje acotado entre 0 y 1; el valor 11.204375 es ~11× el máximo válido

3. Inconsistencias Detectadas — Resumen

Las inconsistencias encontradas se agrupan en tres categorías:

- **Errores de texto:** typo "sweing" y espacio en "finishing " en la columna `department`, que generan categorías duplicadas y rompen los agrupamientos por departamento.
- **Errores de tipo:** el valor "invalid_value" en la columna numérica `team` impide su uso directo en cálculos y agrupamientos.
- **Outliers extremos:** `smv = 545.6 min` y `over_time = 129 600 min` son valores físicamente imposibles. `actual_productivity` presenta 43 valores fuera del rango [0,1]: 11 registros con valor 11.204375 (probable error de sistema) y 32 registros levemente por encima de 1 (probable error de redondeo).

4. Cambios Realizados — Limpieza de Datos

a. Decisiones tomadas

Problema	Decisión	Justificación
Typo "sweing" y espacio en "finishing "	Corregir con <code>.str.strip()</code> y <code>.str.replace()</code>	Error de tipeo; el valor correcto es conocido y unívoco.
<code>team = "invalid_value"</code>	Convertir a NaN y luego eliminar fila	Valor ininterpretable; la columna es crítica para agrupamientos.
<code>smv = 545.6</code>	Reemplazar con mediana del departamento <i>sewing</i>	Valor imposible; la mediana por grupo preserva la variabilidad real.
<code>over_time = 129 600</code>	Reemplazar con mediana del departamento <i>finishing</i>	Equivale a 90 días de trabajo en un día; físicamente imposible.
Filas sin <code>department</code> o <code>team</code>	Eliminar fila	Sin estas variables no es posible clasificar ni imputar la fila.
Filas sin <code>actual_productivity</code>	Eliminar fila	Es la variable objetivo; sin ella la fila no aporta información útil.
<code>actual_productivity = 11.204375</code> (11 registros)	Eliminar fila	Error extremo (~11× el máximo válido). Al ser la variable objetivo no es posible imputarla.
<code>actual_productivity</code> entre (1, 1.2] (32 registros)	Recortar a 1.0 con <code>clip(upper=1.0)</code>	Leve desborde, probable error de redondeo. Se conserva la fila ajustando al límite válido.
<code>incentive</code> , <code>idle_time</code> , <code>idle_men</code> , <code>no_of_style_change</code> nulos	Imputar con 0	Faltante = ausencia del fenómeno (MNAR). El valor real es 0.
<code>wip</code> nulo en <i>finishing</i>	Imputar con 0	Estructural: no hay WIP en finishing por diseño del proceso.
<code>wip</code> nulo en <i>sewing</i>	Imputar con mediana por equipo	Preserva la variabilidad real de cada equipo.
<code>targeted_productivity</code> nulo	Imputar con mediana por (departamento, día)	La meta varía según departamento y día de la semana.
<code>no_of_workers</code> , <code>smv</code> , <code>over_time</code> nulos	Imputar con mediana por departamento/equipo	La mediana por grupo es robusta ante outliers.
<code>day</code> , <code>quarter</code> nulos	Derivar desde <code>date</code>	Recuperables vía <code>dt.dayofweek</code> y mapeo mes → quarter.
<code>quarter</code> nulo con <code>date</code> disponible	Derivar desde día del mes	Días 1–7 → Quarter1, 8–14 → Quarter2, 15–21 → Quarter3, 22+ → Quarter4. Consistente con la definición de la variable (semana dentro del mes, no trimestre del año). Se recuperaron 55 valores; 5 permanecen nulos por no tener fecha.
Filas duplicadas (10)	Eliminar duplicados	Registros redundantes que sesgan las estadísticas.

b. Modificaciones aplicadas

1. Corrección de typos y espacios en `department`.
2. Conversión de `team` a numérico; `"invalid_value"` → NaN.
3. Corrección de outliers extremos en `smv` y `over_time` antes de imputar.
4. Eliminación de filas sin `department`, `team` o `actual_productivity`.
5. Eliminación de 10 filas duplicadas.
6. Imputación con 0 para variables MNAR y `wip` en `finishing`.
7. Imputación por mediana de grupo para el resto de las variables.
8. Derivación de `day` y `quarter` desde `date` donde fue posible.

Resultado

1 207 Filas originales	1 013 Filas tras limpieza	194 Filas eliminadas (16.1%)	32 Valores recortados a 1.0
----------------------------------	-------------------------------------	---	--

El dataset limpio fue guardado como `Tema_11_clean.csv`. De las 194 filas eliminadas, ~183 corresponden a registros vacíos o sin información crítica, y 11 corresponden a valores de `actual_productivity` extremadamente incorrectos (11.204375). Adicionalmente, 32 registros con `actual_productivity` levemente por encima de 1 fueron recortados a 1.0.

5. Normalización de Datos

a. Normalización de variables continuas

Se normalizaron las variables numéricas continuas: `smv`, `wip`, `over_time`, `incentive`, `idle_time`, `idle_men`, `no_of_workers` y `no_of_style_change`. Se aplicaron dos métodos:

Min-Max Scaling

$$x' = (x - \text{mín}) / (\text{máx} - \text{mín}) \rightarrow \text{resultado} \in [0, 1]$$

Transforma todos los valores al rango [0, 1] preservando la distribución original. Útil cuando el rango de la variable está bien definido.

Estandarización Z-score

$$x' = (x - \mu) / \sigma \rightarrow \text{media} = 0, \text{desviación estándar} = 1$$

Centra los datos y los escala por la desviación estándar. Más robusto ante distribuciones asimétricas y valores extremos.

b. Ventajas y posibles usos

Ventaja	Detalle	Uso recomendado
Igualar escalas	Evita que <code>over_time</code> (miles) domine sobre <code>idle_men</code> (decenas)	Todos los algoritmos
Convergencia rápida	El gradiente descendente converge mejor con variables en escalas similares	Redes neuronales, regresión
Distancias correctas	Variables de alta magnitud no dominan la distancia euclidiana	KNN, K-Means, SVM
Min-Max: preserva forma	Mantiene la distribución original; resultado en [0, 1]	Redes neuronales, visualización
Z-score: robusto a outliers	Menos sensible a extremos; centrado en media = 0	Regresión lineal, SVM, PCA
Comparabilidad	Permite comparar la importancia relativa de las predictoras	Feature importance, interpretación

6. Data Profiling — Comparación con Análisis Manual

Se generó un reporte de profiling propio (`reporte_profiling_manual.html`) dado que las librerías estándar (`ydata-profiling`, `sweetviz`) no son compatibles con Python 3.14 en este entorno.

Hallazgo	Análisis manual	Profiling automático
Valores faltantes por columna	Sí — <code>isnull().sum()</code> con %	Sí — sección Missing con conteo y % automáticos
<code>team = "invalid_value"</code>	Sí — detección manual con <code>unique()</code>	Sí — alerta de tipo mixto en columna <code>team</code>
Typo y espacio en <code>department</code>	Sí — 3 categorías detectadas con <code>unique()</code>	Sí — detecta 3 categorías donde deberían ser 2

<code>smv = 545.6 outlier</code>	Sí — boxplot y filtro manual	Sí — alerta de outlier en distribución de <code>smv</code>
<code>over_time = 129</code> <code>600 imposible</code>	Sí — filtro manual > 25 000	Sí — alerta de outlier extremo en <code>over_time</code>
Filas duplicadas	Sí — <code>duplicated().sum()</code>	Sí — sección Duplicates con conteo
Correlaciones entre variables	Parcial — heatmap seleccionado	Completo — correlación automática entre todos los pares
Distribuciones sesgadas (skewness)	Parcial — histogramas visuales	Completo — alerta automática de skewness y cero-inflación
Interpretación contextual del faltante	Sí — wip en finishing = estructural	No — sólo describe, no interpreta causa
Decisión de tratamiento	Sí — estrategia justificada por columna	No — describe el problema, no prescribe solución

El profiling automático confirma en pocos segundos todos los hallazgos del análisis manual y agrega valor en correlaciones y alertas de distribución. Sin embargo, no puede reemplazar el juicio experto para interpretar causas (como el carácter estructural del faltante en `wip`) ni para decidir el tratamiento adecuado de cada problema.

Conclusiones

- **El dataset presentaba problemas de calidad en las 15 columnas.** La mayoría provenía de ~60 filas completamente vacías y errores de ingreso (typos, espacios, valores imposibles). La alta ausencia en `wip` (44.66%) es de naturaleza estructural y esperada para el departamento finishing.
- **Se detectaron dos outliers físicamente imposibles** que habrían distorsionado cualquier análisis posterior: `smv = 545.6 min` (~36× la mediana) y `over_time = 129 600 min` (equivalente a 90 días de trabajo en un solo día). Ambos fueron corregidos con la mediana del grupo correspondiente.
- **La limpieza eliminó el 15.2% de los registros** (183 de 1 207), fundamentalmente filas vacías y filas sin información en columnas críticas no imputables. El dataset resultante (1 024 filas) no contiene nulos ni inconsistencias.
- **La normalización es indispensable** dado que las variables tienen rangos muy distintos. Se prefiere Z-score para los modelos planificados (regresión, SVM), aunque Min-Max queda disponible para redes neuronales.
- **Análisis manual y profiling automático son complementarios** y no excluyentes: el profiling es rápido y exhaustivo en métricas; el análisis manual es imprescindible para comprender el contexto de los datos y tomar decisiones fundamentadas.

Limitantes

- **Valores nulos restantes en variables temporales:** tras la limpieza quedan 47 nulos en `date`, 5 en `quarter` y 2 en `day`, correspondientes a filas donde la fecha tampoco estaba disponible para derivarlos. Se conservaron las filas dado que `date` no es una variable predictora directa y los demás campos de esas filas son válidos y útiles para el análisis.
- **Imputación por mediana de grupo:** este método asume que el comportamiento de cada equipo o departamento es relativamente estable en el tiempo, lo cual puede no cumplirse ante cambios operativos puntuales no registrados en el dataset.
- **Filas completamente vacías:** las ~60 filas sin datos no permiten determinar si corresponden a equipos que trabajaron sin reportar resultados o a errores del sistema de registro. Al no poder distinguirlos, se optó por su eliminación.