

Curso: Análisis de datos

Práctico 2

Manipulación de tablas y series de tiempo

En los siguientes ejercicios de los puntos 1 y 2 se utilizará el archivo “starbucks.csv” el cual se trata de una tabla con registros de direcciones de tiendas de Starbucks en California, Estados Unidos.

Para la parte 3 se utilizarán dos archivos csv correspondientes a temperaturas del aire de 2023 y 2024.

Se debe entregar un informe con justificaciones de lo realizado y de los resultados obtenidos en un archivo .ipynb (colab o jupyter notebook) indicando integrantes del equipo de trabajo.

1. Obtención de los datos

- Cargar los datos a estudiar.
- Hacer un resumen con la explicación de las variables del juego de datos.
- Imprimir los primeros datos.

2. Operaciones con tablas

- Utilizando loc obtener el nombre de la tienda que se encuentra en la dirección ‘1444 Shattuck Place Berkeley CA’
- En una línea de código, obtener todos los registros que tengan a Berkeley como ciudad.
- Agregar los datos de latitud y longitud en nuevas columnas usando la información de la columna Address mediante la librería geopy.geocoders:

```
from geopy.geocoders import Nominatim  
  
geolocator = Nominatim(user_agent="kaggle_learn")
```

```
location = geolocator.geocode("1799 Solano Avenue Berkeley  
CA")  
print(location.address)  
print((location.latitude, location.longitude))
```

- d. Realizar lo mismo para todos los registros, si da un error capturar el mismo y guardar la dirección en una lista.
- e. Para los casos en que falló el código, observar las direcciones e intentar modificarlas para que se pueda agregar latitud y longitud de las mismas.
- f. Remover de la columna 'Address' el texto que contiene el nombre de la ciudad + 'CA' utilizando el valor de la columna 'City' (tener en cuenta que los nombres de Ciudades pueden haberse escrito de distinta forma ej. Yucaipa y YUCAIPA).
- g. Crear una columna nueva en la que se asigne la distancia a las tiendas respecto a la dirección de Legoland, California. Ordenar los registros de menor a mayor distancia.

Ejemplo de cálculo de distancia:

```
from geopy.distance import geodesic  
  
berkeley = (37.8716, -122.2727)  
los_angeles = (34.0522, -118.2437)  
  
distancia = geodesic(berkeley, los_angeles).kilometers
```

- h. Crear un índice a partir del nombre de la tienda.
- i. Agrupar tiendas por ciudad y mostrar los primeros 5 registros.
- j. **Opcional:** Calcular las distancias entre todas las tiendas de una misma ciudad y obtener el promedio de distancias para cada ciudad. Ordenarlos de menor a mayor.

3. Manejo de series de tiempo

- a. Cargar archivos csv en dos dataframes.
- b. Unir ambos dataframes en una sola tabla.

- c. Graficar el comportamiento de la temperatura en función del tiempo.
- d. Crear un filtro para poder ver mejor las tendencias.
- e. Graficar la temperatura para distintos períodos de tiempo. Buscando tendencias, cambios, valores anómalos, etc.
- f. Para los datos del último año crear filas con hora = el punto medio entre dos observaciones.
- g. Estimar la temperatura en esos puntos e ingresarla en la tabla.