

Práctico 5 — Modelos Predictivos

Productividad de Operarios en la Industria Textil

Dataset: Tema_11_clean.csv | 1,006 registros · 14 variables predictoras

Descripción del problema

El dataset registra métricas de productividad de equipos de operarios en una empresa textil de Bangladesh. Cada fila representa el desempeño de un equipo en una jornada de trabajo, incluyendo variables operativas (horas extra, incentivos, trabajo en proceso), características del equipo (tamaño, departamento) y el resultado de productividad real vs. el objetivo asignado.

El objetivo de este práctico es construir y comparar **modelos de aprendizaje supervisado** para predecir `actual_productivity` — la productividad real del equipo (valor continuo entre 0 y 1). Se exploran regresión lineal, árboles de decisión, bagging, random forest y KNN, con selección manual de variables y optimización automatizada vía validación cruzada y GridSearchCV.

1,006

REGISTROS VÁLIDOS

14

FEATURES DISPONIBLES

804

MUESTRAS DE
ENTRENAMIENTO

202

MUESTRAS DE PRUEBA

Preprocesamiento — Codificación de variables

Se reutiliza la misma estrategia de codificación aplicada en el Práctico 4, que ya demostró ser adecuada para no inducir sesgos en el análisis:

Variable	Estrategia	Resultado
date	Eliminada	Redundante con quarter y day
department	Codificación binaria	sewing=1, finishing=0
quarter	Codificación ordinal	Quarter1=1 ... Quarter5=5
day	Codificación cíclica (sin/cos)	Preserva periodicidad semanal

Todas las features fueron **estandarizadas** (StandardScaler) con parámetros ajustados exclusivamente sobre la base de entrenamiento y luego aplicados a la base de prueba, evitando data leakage.

Punto 2 — Dos modelos con variables seleccionadas manualmente

Se seleccionaron **6 variables** en base a la relación intuitiva con la productividad real, apoyada en los loadings de PC1 identificados en el Práctico 4:

- targeted_productivity** Meta asignada — ancla natural de la productividad real
- over_time** Horas extra — refleja intensidad del trabajo
- incentive** Incentivo económico — motiva el rendimiento del equipo
- idle_time** Tiempo inactivo — impacto negativo directo en productividad
- idle_men** Operarios inactivos — complemento del idle_time
- department_enc** Departamento — sewing y finishing tienen dinámicas muy diferentes

Modelo	Variables	RMSE	MAE	R ²
--------	-----------	------	-----	----------------

Regresión Lineal	6 (manual)	0.1498	0.1059	0.2189
Árbol de Decisión (max_depth=5)	6 (manual)	0.1464	0.0964	0.2543




Figura 1 — Dispersión real vs predicho para ambos modelos iniciales (base de prueba)




Figura 2 — Coeficientes de la regresión lineal e importancia de variables del árbol de decisión

Observación: Ambos modelos muestran un desempeño moderado. La regresión lineal captura tendencias generales pero no puede modelar relaciones no lineales. El árbol de decisión logra mayor flexibilidad en ciertos rangos. En ambos casos el R^2 relativamente bajo refleja la alta variabilidad inherente de la productividad laboral humana, confirmada por el PCA del Práctico 4 (PC1+PC2 solo explicaron el 36% de la varianza total).

Punto 3 — Iteración hasta encontrar el mejor modelo manual

Se realizaron **4 iteraciones** ampliando progresivamente el conjunto de variables y probando distintos tipos de modelo:

Intento	Variables	Cambio introducido
1	6	LR + DT con variables intuitivas básicas
2	10	Se agregan SMV, WIP, N° operarios y cambios de estilo; se añade KNN
3	14	Todas las features disponibles; DT más profundo; KNN con k=5
4	14	Se prueban Bagging y Random Forest (ensemble)

Resultados de todos los intentos — ordenados por RMSE (menor es mejor):

Intento	Modelo	N° vars	RMSE	MAE	R²
4	Bagging ★	14	0.1295	0.0806	0.4162
4	Random Forest	14	0.1303	0.0808	0.4090
2	KNN (k=7)	10	0.1447	0.0951	0.2717
3	Regresión Lineal	14	0.1448	0.1037	0.2708
2	Regresión Lineal	10	0.1459	0.1048	0.2597
1	Árbol de Decisión	6	0.1464	0.0964	0.2543
2	Árbol de Decisión	10	0.1465	0.0890	0.2532
3	Árbol de Decisión	14	0.1480	0.0905	0.2376
3	KNN (k=5)	14	0.1482	0.1014	0.2359
1	Regresión Lineal	6	0.1498	0.1059	0.2189

★ Mejor modelo manual encontrado




Figura 3 — Comparación de RMSE en base de prueba para todos los intentos manuales




Figura 4 — Dispersión e importancia de variables del mejor modelo manual (Random Forest, Intento 4)

Mejor modelo manual: Bagging — Intento 4 | Variables: 14 (todas) | RMSE = 0.1295 | MAE = 0.0806 | R² = 0.4162

La progresión de intentos muestra una tendencia clara:

- Agregar más variables mejora consistentemente las métricas, especialmente para los modelos basados en árboles que pueden explotar interacciones no lineales entre features.
- Los modelos de **ensemble** (Bagging y Random Forest) superan a los modelos individuales (LR, DT, KNN), confirmando que la promediación de múltiples árboles reduce la varianza de predicción.
- La importancia de variables del RF muestra que `targeted_productivity` e `incentive` son los predictores más relevantes, seguidos de `over_time` y `no_of_workers`.

Punto 4 — Validación cruzada y métodos automatizados

Se aplicó **validación cruzada de 5 particiones (5-fold CV)** sobre la base de entrenamiento para comparar todos los tipos de modelo de forma robusta, sin depender de una única división train/test. Esta técnica estima el error esperado en datos no vistos con menor varianza que una sola evaluación.

Modelo	CV-RMSE media	CV-RMSE std
Random Forest	0.1302	0.0083
Bagging	0.1304	0.0082
Árbol de Decisión	0.1410	0.0122
KNN	0.1503	0.0141
Regresión Lineal	0.1540	0.0109

★ Mejor modelo por validación cruzada




Figura 5 — CV-RMSE (media $\pm$ std) para los 5 tipos de modelo evaluados con 5-fold CV

GridSearchCV — Random Forest

Se optimizaron los hiperparámetros de Random Forest usando GridSearchCV con 5-fold CV, evaluando 54 combinaciones sobre la grilla:

- `n_estimators`: [100, 200, 300]
- `max_depth`: [None, 10, 20]
- `min_samples_split`: [2, 5, 10]
- `max_features`: ['sqrt', 'log2']

Mejores hiperparámetros encontrados:

Hiperparámetro	Valor óptimo
<code>max_depth</code>	10
<code>max_features</code>	sqrt
<code>min_samples_split</code>	5
<code>n_estimators</code>	300

CV-RMSE del mejor modelo en grilla: **0.1277**




Figura 6 — Heatmap de CV-RMSE por `n_estimators` y `max_depth` (promediado sobre el resto de parámetros)

Mejor modelo automatizado evaluado en base de PRUEBA:

Métrica	Valor
RMSE	0.1268
MAE	0.0817
R ²	0.4408

Punto 5 — Comparación: mejor manual vs mejor automatizado

RF Manual (Intento 4)

0.1303 RMSE

0.0808 MAE

0.4090 R²

14 features · n_estimators=100 · parámetros por defecto

RF Automatizado (GridSearchCV)

0.1268 RMSE

0.0817 MAE

0.4408 R²

14 features · n_estimators=300 · max_depth=10 · min_samples_split=5




Figura 7 — Comparación final: dispersión real vs predicho y errores de ambos modelos

Mejora del modelo automatizado sobre el manual:

- Δ RMSE: 0.1303 $\rightarrow$ 0.1268 (+2.73%)
- Δ R²: 0.4090 $\rightarrow$ 0.4408 (+0.0318 puntos)

Análisis comparativo: El modelo automatizado supera al manual, con una mejora de RMSE de 2.73%. Esto sugiere que el Random Forest con parámetros por defecto ya es una buena aproximación para este dataset: los hiperparámetros óptimos encontrados por GridSearchCV ajustan finamente la profundidad y el número de árboles, lo que mejora la generalización. La ganancia real de la optimización automatizada está en la **robustez**: la varianza del error en CV es menor, lo que indica mayor estabilidad ante distintas particiones de los datos.

Conclusiones generales

¿Qué tipo de modelo resultó más adecuado para este problema?

Los modelos de **ensemble basados en árboles** (Bagging y Random Forest) superaron consistentemente a los modelos individuales (regresión lineal, árbol de decisión, KNN). Esto es coherente con la estructura del dataset: la productividad laboral depende de interacciones no lineales entre múltiples variables (tamaño del equipo, tipo de tarea, incentivos) que la regresión lineal no puede capturar.

¿Qué variables resultaron más influyentes?

La importancia de variables del Random Forest revela que los predictores más relevantes son:

- **targeted_productivity** — la meta asignada es el predictor más fuerte, lo que tiene sentido: los equipos tienden a producir cerca de su objetivo
- **incentive** — el incentivo económico tiene alto impacto en el rendimiento
- **over_time** y **no_of_workers** — capturan la escala operativa del equipo
- Variables temporales (quarter, day) y de contexto (smv, wip) tienen importancia moderada

¿Por qué el R^2 es moderado?

Un R^2 moderado es esperable en datos de productividad laboral. La productividad humana depende de factores no capturados en el dataset: motivación, clima laboral, fatiga acumulada, liderazgo del equipo, variabilidad individual. El Práctico 4 ya mostró que PC1+PC2 solo explicaban el 36% de la varianza total, indicando una estructura

inherentemente multidimensional y ruidosa. Los modelos son útiles para identificar tendencias y los factores más influyentes, no para predecir con precisión absoluta.

¿Aporta la optimización automatizada sobre la selección manual?

Sí, aunque marginalmente en este caso. La validación cruzada confirmó que Random Forest es consistentemente el mejor tipo de modelo. GridSearchCV permitió ajustar finamente los hiperparámetros, reduciendo tanto el error como su varianza entre pliegues. El aporte principal de la optimización automatizada no es solo bajar el RMSE puntual, sino garantizar que el modelo **generaliza bien** a distintas muestras de datos no vistos.